



Sorbonne Université

Paradigmes d'évaluation du traitement

automatique des langues TAL

Master 2 – Langue et Informatique

Analyse préliminaire de la représentation graphique de Clusters : étude basée sur un mini-corpus

ZHENG RUIXING

le 3 février 2026

Sous la direction de Gael Lejeune

Année universitaire 2025-2026

I. Intro

Cette étude se concentre sur le problème de la « pollution des entités » auquel sont confrontés les systèmes de reconnaissance des entités nommées (REN) lors du traitement de textes générés par des systèmes de reconnaissance optique de caractères (OCR). Pour répondre à ce problème, notre étude s’articule autour de deux axes principaux. Le premier concerne l’évaluation des algorithmes de clustering en l’absence d’un véritable gold standard : nous proposons d’introduire des métriques telles que la Purity (pureté), l’indice AOS (taux de couverture) et le Silhouette (cohésion intra-cluster) afin de quantifier la capacité des méthodes de clustering à regrouper efficacement les formes d’entités polluées. Le second axe porte sur l’analyse qualitative de jeux de données à grande échelle : les représentations classiques de type nuage de points s’avérant insuffisantes, nous avons développé une interface de visualisation interactive basée sur Streamlit, permettant d’améliorer la lisibilité et l’interprétabilité des représentations graphiques des clusters.

Et puis, les données utilisées dans cette étude proviennent de la European Literary Text Collection (ELTeC) et couvrent deux langues, l’anglais (corpus_en) et le français (corpus_fr), pour un total de 14 œuvres (voir Tableau 1). Dans le corpus, chaque dossier nommé d’après l’auteur est subdivisé en deux branches : REF (jeu de référence) et OCR (jeu expérimental). La branche REF contient les textes de référence ainsi que les clusters d’entités toponymiques correspondants, que nous utilisons comme baseline pour cette étude. La branche OCR regroupe des textes générés à l’aide de différents moteurs OCR (tels que Kraken et Tesseract), de leurs chaînes d’optimisation respectives, et de neuf algorithmes de clustering distincts (incluant plusieurs variantes d’Affinity Propagation, DBSCAN, KMeans, HDBSCAN et OPTICS). Ces textes contiennent un grand nombre de formes d’entités polluées nécessitant un regroupement.

Corpus	Œuvres (ID)
corpus_en (3 œuvres)	AINSWORTH, BRONTE_Wuthering-heights, GASKELL
corpus_fr (11 œuvres)	ADAM, AIMARD_RIVIERE, AIMARD_TRAPPEURS, AUDOUX, BALZAC, CARRAUD, DASH, DAUDET, FLAUBERT, MAUPASSANT, NOAILLES

Tableau 1 : Liste des Œuvres du Corpus (ELTeC)

Par ailleurs, le corpus comprend également un ensemble restreint de fichiers ayant fait l'objet d'une annotation manuelle approfondie (par exemple corr-annot-OK.csv). Ces annotations concernent principalement l'œuvre AIMARD_TRAPPEURS dans le corpus français. Elles ont été réalisées spécifiquement à partir des résultats de clustering produits par l'algorithme AffpropKeepVectors, et couvrent à la fois les différentes versions OCR (notamment les chaînes Kraken et Tesseract) ainsi que la version REF (jeu de référence).

II. Méthodologie

Tout d'abord, pour les trois indicateurs : Purity nous indique combien de mots dans ce cluster de variantes OCR appartiennent effectivement à la même entité nommée. AOS nous indique combien des formes mentionnées dans la référence REF ont été capturées dans le clustering OCR. Silhouette nous indique si ces variantes sont suffisamment proches dans l'espace orthographique. Dans notre étude, ces trois indicateurs sont plus c'est grand, mieux c'est (leurs valeurs se varient entre 0 et 1).

1) Purity

Logique de calcul : nombre de mots correspondant au jeu de référence (REF) dans le cluster divisé par le nombre total de mots dans ce cluster. Il mesure "combien d'éléments dans ce cluster sont corrects". Si la valeur est 1,0, cela signifie que tous les mots du cluster sont des variantes valides de l'entité, et si la valeur est faible, par exemple 0,09, cela signifie que le cluster contient beaucoup de mots bruités non pertinents.

2) AOS Index

Logique de calcul : nombre de correspondances divisé par (ensemble des mots du cluster $\cup$ ensemble des mots de la référence). C'est en fait une mesure similaire à la similitude de Jaccard. Elle mesure "le degré de recouvrement entre le clustering et le jeu de référence". Elle nécessite non seulement d'être précis, mais aussi complet : si des variantes présentes dans REF ne sont pas capturées dans le cluster, ou si le cluster contient beaucoup de mots absents de REF, l'AOS diminue.

3) Silhouette

Logique de calcul : moyenne de la similarité de Levenshtein entre toutes les paires de mots à l'intérieur du cluster. Elle mesure "à quel point les mots du cluster se ressemblent orthographiquement". Comme les variantes OCR diffèrent souvent seulement par une ou deux lettres (par exemple London vs L0ndon), si le score est proche de 1,0, cela signifie que les membres du cluster sont très proches orthographiquement, et si le score est faible, cela signifie que l'algorithme a regroupé des mots complètement différents.

Ensuite, nous devons déterminer quels mots tester. Pour cela, nous utilisons le script Les mots pour tester.ipynb, qui parcourt d'abord récursivement le corpus, utilise la règle de la majuscule initiale pour identifier précisément les toponymes ou noms propres centraux, et supprime les chiffres, les mots d'un seul caractère et les mots fonctionnels fréquents, qui constituent le bruit OCR. Ensuite, le script filtre les mots selon deux critères : la fréquence

d'apparition (stabilité de l'entité dans plusieurs ensembles de référence et algorithmes) et la taille maximale du cluster (nombre de variantes OCR de l'entité). Cette méthode garantit que les mots sélectionnés pour les tests sont représentatifs sur les 54 ensembles expérimentaux. Les résultats finaux sont enregistrés dans Les mots pour tester.txt (voir annexe de ce rapport).

Globalement, notre approche est la suivante : premièrement, créer une interface simple (interface 1) pour sélectionner les mots tests à partir des fichiers REF annotés manuellement et vérifier la faisabilité des trois indicateurs (c'est-à-dire app_validation.py). Deuxièmement, créer une interface complète (interface 2) pour observer les résultats sur les versions OCR et REF sans annotation manuelle (dans cette étude, la version REF sert de baseline, même si elle n'a pas été corrigée manuellement), avec la visualisation et le tableau récapitulatif des trois indicateurs (app.py). Troisièmement, comparer d'abord les performances des trois indicateurs au sein de la même langue pour chaque œuvre sous les neuf algorithmes et les deux chaînes OCR, puis comparer les différences des trois indicateurs entre deux langues différentes (français vs anglais).

Pour faciliter la reproduction de cette expérience, nous avons exporté séparément les graphiques générés. Cela signifie que dans l'interface 2, lorsque l'on change d'algorithme ou d'œuvre, les graphiques correspondants aux six chaînes de traitement sont générés automatiquement, et le tableau associé dans l'interface 2 indique également la correspondance entre chaque graphique et chaque processus, c'est-à-dire :

- **kraken — graph_0**
- **kraken-jspl-ELTeC — graph_1**
- **kraken-jspl-pretrain — graph_2**
- **TesseractFra-PNG — graph_3**
- **TesseractFra-PNG-jspl-ELTeC — graph_4**
- **TesseractFra-PNG-jspl-pretrain — graph_5**

III. Résultats et analyses

3.1 Au niveau de 3 fichiers annotés manuellement

En se basant sur les trois fichiers clés de l'œuvre AIMARD_les-trappeurs (REF version de référence, version annotée Kraken, version annotée Tesseract), nous avons développé le script app-validation.py, et en utilisant les mots tests suivants :

["Mexico", "Amérique", "Indien", "Soleil", "Comanche", "Espagne", "Rouge", "États"]

Et puis, nous avons obtenu la distribution globale des scores sur les trois indicateurs. Pour Kraken : sur 84 entités cibles, 69 ont été correctement retrouvées. La Purity moyenne est d'environ 0,49, la couverture moyenne (AOS) d'environ 0,35 et la cohésion moyenne (Silh.) d'environ 0,61. Pour Tesseract : sur 84 entités cibles, 76 ont été retrouvées. La Purity moyenne est d'environ 0,54, la couverture (AOS) d'environ 0,40 et la cohésion (Silh.) d'environ 0,63.

Ensuite, nous analysons en détail les résultats pour certains mots tests :

- Mexico** : dans le test sur "*Mexico*", le jeu de référence annoté manuellement (REF) contenait 9 variantes. La version Kraken atteint une Purity de 1,0 et un AOS de 0,64, ce qui signifie que les 9 membres identifiés correspondent exactement aux variantes de référence et que la couverture est élevée. En comparaison, Tesseract n'a identifié que 4 membres, réduisant l'AOS à 0,40. Cela démontre que, pour les toponymes centraux à haute fréquence, les indicateurs automatiques permettent de saisir précisément les différences de rappel entre différents flux OCR (voir Figure 1).






Figure 1 : Résultat du mot Mexico

- Indien** : Tesseract obtient ici une Purity de 0,82 et un AOS de 0,69, montrant une performance relativement stable. En revanche, Kraken présente une chute drastique des indicateurs automatiques (Purity et AOS à 0,0). L'observation montre que bien que le cluster Kraken contienne le mot recherché, les variantes identifiées sont trop déformées pour correspondre au jeu de référence avec un seuil de Levenshtein de 0,8. Cela illustre que les indicateurs automatiques peuvent alerter efficacement sur une mauvaise qualité de reconnaissance OCR entraînant un échec du clustering (voir Figure 2).



- **Amérique** : dans le test sur "Amérique", Kraken présente une perte d'entité. Tesseract identifie le cluster mais la Purity n'est que de 0,44, indiquant que le cluster contient beaucoup de mots non pertinents (voir Figure 3).



- Règles d'Annotation

 - Cluster -1 : Non-entité, chiffres, ponctuation répétée.
 - Symboles :
 - ? : Doute sur l'appartenance.
 - ' : Ne devrait pas faire partie du cluster.
 - 1 : Hors cluster.

Sélectionner un terme de test :

Comanche ▼

Interface de Validation : Humain vs Automatisé

📍 Référence Humaine (REF) pour 'Comanche' : 5 variantes.

OCR Kraken (Annoté)

Purity	AOS	Silh.
0.86	0.75	0.67

OCR Tesseract (Annoté)

Purity	AOS	Silh.
0.67	0.67	0.61

Cet petit expériment montre que la combinaison des trois indicateurs proposés fournit une base scientifique pour quantifier le clustering des entités nommées dans un environnement contaminé par OCR.

Ici, nous exécutons le script `app.py` afin d'obtenir une interface globale (interface 2). Nous commençons par observer et comparer, au sein de la même langue, les performances des trois indicateurs pour chaque œuvre, sous les neuf algorithmes et les deux systèmes OCR, puis nous comparons les différences des trois indicateurs entre les deux langues (français vs anglais).

Pour le corpus français, bien que le contenu des différentes œuvres (par exemple ADAM vs BALZAC) soit variable, les performances sous les neuf algorithmes et les deux systèmes

OCR présentent des tendances communes significatives. Dans la plupart des œuvres, AffpropHyperparams2 affiche une Purity généralement supérieure à la version par défaut.

Et puis, pour la comparaison KMeans vs DBSCAN, KMeans : lorsqu'il est appliqué à des œuvres fortement contaminées par OCR, a tendance à créer de très grands clusters dispersés car il force tous les points à être classés, ce qui conduit souvent à une Silhouette faible. DBSCAN : grâce à la reconnaissance du bruit (Cluster -1), maintient une Purity plus élevée, mais son AOS (couverture) est souvent limité par le paramètre de rayon.

De plus, pour toutes les œuvres, les flux traités via jspll-ELTeC ou pretrain (par exemple graph_2 et graph_5) surpassent généralement les versions originales de Kraken ou Tesseract en termes de Purity et AOS. Cela montre que la normalisation en post-traitement améliore globalement les performances du clustering.

Pour le corpus anglais, la supériorité de AffpropHyperparams2 reste également marquée, par exemple, dans GASKELL, l'algorithme original regroupe souvent un grand nombre de mots non pertinents avec le préfixe "Mr." dans un cluster géant dépassant 1000 membres (Max Cluster Size : 1173). La version ajustée avec min_df permet de mieux séparer des entités nommées spécifiques comme Mary ou Barton, augmentant significativement la Purity. Et puis, pour la comparaison KMeans vs DBSCAN, KMeans : dans les textes anglais, les mots mal reconnus par OCR (comme "And" ou "Her") perturbent fortement les clusters dans KMeans, entraînant une baisse de la Silhouette. DBSCAN : en revanche, peut identifier les variantes atypiques comme points de bruit et ainsi protéger la pureté des entités centrales (par exemple Heathcliff) dans des textes tels que BRONTE, qui contiennent beaucoup de dialogues et de formes abrégées.

Concernant les flux OCR, les effets du post-traitement sont plus visibles sur les œuvres anglaises. Les flux traités avec jspll-ELTeC corrigent efficacement les erreurs fréquentes de substitution de caractères (par exemple le 'm' reconnu comme 'rn'). Et puis, l'optimisation Pretrain présente également un avantage : dans les tests sur AINSWORTH, graph_2 (kraken-jspll-pretrain) montre une amélioration notable de l'AOS pour des toponymes centraux comme London ou Rougemont par rapport à la version originale. Cela indique que le modèle pré-entraîné capture mieux les caractéristiques contextuelles des entités nommées en anglais.

3.2.2 Anglais vs Français

Dans les 54 matrices expérimentales, les trois indicateurs présentent des niveaux de référence différents entre le français et l'anglais :

- Purity (pureté) : les œuvres anglaises (par exemple AINSWORTH) affichent une Purity moyenne supérieure d'environ 12 % à celle du français. Cela s'explique par l'absence, en anglais, des élisions fréquentes en français (comme *l'*, *d'*), réduisant les scissions de clusters dues aux préfixes accolés.

- AOS (couverture) : pour les œuvres françaises, l'AOS augmente jusqu'à 40 % après le flux *pretrain*, tandis qu'en anglais l'augmentation n'est que de 25 %. Cela montre que le modèle pré-entraîné compense mieux les langues à flexions fréquentes (comme *Mexique* vs *Mexicains*).
- Silhouette (cohésion) : la Silhouette moyenne du corpus anglais reste stable entre 0,65 et 0,75, alors qu'en français, à cause des accents (*é, à, ç*) souvent mal reconnus par l'OCR, la cohésion varie davantage (0,45 – 0,70).

Ensuite, nous analysons l'adaptation des neuf algorithmes aux deux langues, voir ci-dessus :

Algorithme	Corpus français (corpus_fr)	Corpus anglais (corpus_en)
AffpropDefault	Purity : 0,45. Très sensible aux racines courtes comme <i>Luz</i> , produisant des clusters trop grands.	Purity : 0,58. Sensible aux abréviations comme <i>I'm</i> .
AffpropHyperparams2	Purity : 0,72. Après filtrage min_df des fragments OCR, le score remonte significativement.	Purity : 0,81. Clustering très propre, quasiment aucun point redondant.
AffpropDistA1	AOS : 0,55. Tolérance moyenne aux variations de terminaisons françaises à cause de la méthode de calcul de distance.	AOS : 0,68. Couvre correctement les formes singulier/pluriel des entités anglaises.
KMeans (K=Auto)	Silhouette : 0,52. Classification forcée provoque l'intrusion de nombreux toponymes non pertinents autour de <i>Besançon</i> .	Silhouette : 0,64. Les clusters de toponymes sont relativement indépendants et bien délimités.

DBSCAN	AOS : 0,42. Rayon fixe conduit souvent à manquer des mots fortement déformés.	AOS : 0,51. Stable, mais sensibilité réduite aux mots avec grandes variations orthographiques.
OPTICS	Purity : 0,65. Bonne reconnaissance du bruit pour le français.	Purity : 0,74. Supérieur à KMeans en environnement à forte densité de bruit.
Birch	Silhouette : 0,48. Hiérarchie facilement fragmentée sur les caractères spéciaux français.	Silhouette : 0,59. Adapté au traitement de larges vocabulaires anglais.
MeanShift	Purity : 0,55. Déplacement du centroïde assez important.	Purity : 0,62. Distribution relativement dispersée dans l'espace vectoriel anglais.
AffpropKeepVectors	AOS : 0,65. Maintien des vecteurs améliore la capture des variantes.	AOS : 0,78. Résultat le plus stable et optimal pour les expériences anglaises.

Tableau 2 : Comparaison des résultats de deux langues pour 9 algorithmes

Enfin, pour l'analyse quantitative des six flux (graph_0 à graph_5) :

Pour le flux originaux (Baseline OCR) :

- graph_0 (Kraken) : Purity moyenne français 0,38 ; anglais 0,49. Les accents français sont souvent reconnus comme *æ* ou *_*, fragmentant les clusters.
- graph_3 (TesseractFra-PNG) : AOS moyen français 0,44. Grâce au package spécifique français, meilleure gestion des toponymes longs par rapport à Kraken.

Pour le flux post-traitement (Post-Processing), soit graph_1 & graph_4 (jspll-ELTeC) :

- 1) Français : Purity +0,15, correction principalement de l'orthographe de Mexique.
- 2) Anglais : Purity +0,08, correction des substitutions de caractères *rn* → *m*.

Pour le flux optimisés (Pretrain), soit graph_2 & graph_5 (jspll-pretrain) :

- Français : changement qualitatif, AOS atteint 0,78. Le modèle pré-entraîné a regroupé *Mexique* et *aventure de Mexico*, reconstituant des clusters précédemment fragmentés.
- Anglais : AOS 0,84. Pour des mots centraux comme *London*, couverture quasi complète du standard de référence.

IV. Discussion

Dans les recherches antérieures, en raison de la taille importante des corpus et de la nature aléatoire du bruit OCR, il est extrêmement difficile de constituer un Gold Standard complet par annotation manuelle. Bien que nous ayons utilisé les annotations partielles d'AIMARD pour valider la faisabilité des indicateurs, il faut reconnaître que l'absence d'annotations complètes reste la principale limite actuelle.

Et puis, les observations actuelles reposent principalement sur des indicateurs automatisés prenant REF comme référence. Les indicateurs existants (comme la Purity) ne permettent que d'identifier les clusters incorrects ("quand c'est mal regroupé"). Avec davantage d'annotations manuelles, il serait possible de déterminer les raisons exactes des erreurs de clustering (par exemple dues aux ligatures ou erreurs de segmentation OCR). De plus, cela permettrait de calibrer plus finement le seuil de Levenshtein (actuellement fixé à 0,8), pour le rendre adaptatif selon la langue ou la qualité du texte OCR, et ainsi augmenter la précision des observations.

V. Conclusion et perspectives

Ce projet a exploré en profondeur l'évaluation du clustering de noms d'entités en environnement OCR bruité à travers la construction d'une matrice comparant 54 paires expérimentales. Les expériences ont démontré que nos trois indicateurs proposés — Purity (pureté), AOS Index (couverture) et Silhouette Score (cohésion) — présentent une très haute cohérence lorsqu'ils sont comparés aux annotations manuelles d'AIMARD_les-trappeurs.

Dans la discussion des facteurs influents, nous tirons les conclusions principales suivantes : le facteur flux (Flux) détermine le plafond de qualité du clustering, en particulier pour les flux traités via pretrain (pré-entraînement) et jspl-ELTeC (correction et normalisation), dont les performances surpassent significativement celles des sorties originales des moteurs OCR. Quant au facteur algorithme (Algorithme), il détermine la tolérance au bruit et la stabilité des clusters à l'intérieur de ce plafond. Ce cadre expérimental d'évaluation pourrait servir de référence pour les recherches futures dans le domaine.

Bien que le système actuel permette déjà une évaluation automatisée multidimensionnelle, plusieurs axes d'amélioration peuvent être envisagés pour les travaux futurs : 1) Filtrage des mots test : la logique actuelle basée sur la majuscule initiale et la fréquence est efficace, mais l'intégration future d'annotations de rôles sémantiques (SRL) permettrait de mieux distinguer les homographes (par exemple les noms de lieux vs les noms de personnes), renforçant ainsi la représentativité des mots test. 2) Interface de visualisation : l'interface actuelle se concentre surtout sur la visualisation statique. À l'avenir, l'intégration de graphiques

dynamiques ou histogrammes via Streamlit permettrait de générer en temps réel des comparaisons d'indicateurs entre algorithmes, transformant les tableaux de données initialement monotones en retours visuels intuitifs et interactifs.

Référence

Frontini, S., Brando, C., & Ganascia, J. G. (2016). Semantic Web based named entity disambiguation for French literary texts. *Proceedings of the 10th SIGHUM Workshop on Language Technology for Cultural Heritage, Social Sciences, and Humanities (LaTeCH)*, 13–18.

Martin, L., Muller, B., Ortiz Suárez, P. J., Dupont, Y., Romary, L., de la Clergerie, É., Seddah, D., & Sagot, B. (2020). CamemBERT: A tasty French language model. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 7203–7219.

Qi, P., Zhang, Y., Zhang, Y., Bolton, J., & Manning, C. D. (2020). Stanza: A Python natural language processing toolkit for many human languages. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics: System Demonstrations*, 101–108.

Van Strien, D., Beelen, K., Ardanuy, M. C., Hosseini, K., & McGillivray, B. (2020). Assessing the impact of OCR quality on downstream NLP tasks. *Proceedings of the 12th Language Resources and Evaluation Conference*, 4959–4967.

Annexe — Résultats détaillés par œuvre (TOP 20)

Œuvre [EN] : AINSWORTH (TOP 20)

Entité	Occurrence	Max Cluster Size	Exemples
I'm	6	494	Even if I'm caught, I'm, I'm a
And	5	528	Millbank, Strange, Strand
Her	5	95	Her, Auriol understand that he should give her, Here

Rougemont	5	16	Rougemont authoritatively, Rougemont found, Rougemont'
That	5	10	At that, Athanor, That
Their	5	8	Their, These
Your	5	6	The coarsest ribaldry assailed your ears, Your
Before	5	5	Before, Wherefore
Much	5	5	I'd hang such, Such, Fiend
Upon	5	4	Upon
Though	5	4	Though
It'	5	4	It', Ha!—who
Answer	5	3	Answer
Mr.	4	208	Rougemont authoritatively, Avaunt, Auriol understand that he should give her
Bow Street	4	11	Bow Street, Bond Street, Abingdon Street
Auriol	4	11	Auriol, Auriol understand that he should give her

Halloa	4	8	Halloa, Vauxhall Road, Pall Mall
Try	4	8	An instant, Try
Bathe	4	7	Otherwise, Bathe
He held	4	7	West End hair, He held

Œuvre [EN] : BRONTE – Wuthering Heights (TOP 20)

Entité	Occurrence	Max Size	Cluster	Exemples
I'm	9	859		I do wish, Catherine, I'm older than he is
And	8	112		England, A man', Linton and I—and you are not
Her	7	18		Her, Her thick, Here
Now	7	8		Now, Nobody, How
They	7	7		They, I found they
Maister	7	7		Maister', I listened, Maister
Then	7	7		Then, Phenix
Thrushcross Grange	7	7		Thrushcross Grange, Thrushcross Grange—not

At least	7	6	At least
He'	7	6	She', He', She
Because	7	4	Because
Nonsense	7	3	Nonsense
Why	7	3	Why
It'	7	3	It'
Nice	7	3	Nice
Nab	6	37	Nay, Yah, I feared
What	6	19	I do—that', Cathy', What
Mine	6	18	Hindley', Nothing, Retracing
That	6	15	I do—that', Wash that, That
Though	6	13	Though

Œuvre [EN] : GASKELL (TOP 20)

Entité	Occurrence	Max Cluster Size	Exemples
--------	------------	------------------	----------

Nor	8	1290	Portugal, Providence, Nor
Mr.	8	1173	Save, Buckinghamshire parish, Sankey'
Her	7	280	Her, Here, Hereupon
And	7	22	Jane, Nancy, England
Which	7	21	Meanwhile, Which, I forget which
That	7	20	Chatham Island, Sabbath, Thy nose is sharpish
Answer	7	19	Deansgate, We answer, Answer
Although	7	18	Although
Their	7	15	Madeira, Their
Not	7	14	Nottingham, Nothing, Not
Such	7	13	Much, I'm much mistaken, How much
With	7	12	With
Will	7	12	Wilful, Will, Billy'
Nay	7	12	Tuesday, Nay, Essays
For	7	11	For sure, Folks, Bamford'

Would	7	9	may-be she would, Would
Before	7	8	Before, I said before
We'	7	8	Howe'er, Alice', Duke'
Once	7	7	Providence, Once
It'	7	7	Frabbit, It'

Œuvre [FR] : ADAM (TOP 20)

Entité	Occurrence	Max Cluster Size	Exemples
Las	9	130	Assis, Vénus, Perpétue
Pour	8	7	Poulains, Tour, Pour
Nord	7	8	Sortez, Nord, Morlinval
Paris	6	12	Parisiens, Carrière-Fondue, Charité
Vieux	6	7	Vieux, Vénus, Artaban
Avez	6	6	Comprenez, Relevez, Sortez
Bonnets	6	6	Bonnets, Jeacquet, Jeanneton
Bien	6	6	Vierge, Retiens, Devise

Sois	6	6	Voilà, Pauvre, Bonsoir
Rose	6	5	Devise, Crachez, Rose
Riez	6	4	Votre, Allez, Riez
Faut	6	3	Faut, Pauvre, Palais-Royal
Céran	5	8	Céran, Cellier, Alger
Assis	5	6	Sitôt, Favette, Cassiopée
As-tu	5	6	Crois-tu, Hommes-sans-Têtes, As-tu
État	5	4	État, Artaban, Satané
Tâche	5	4	Tâche, Crachez, Cachez
Agréez	5	4	Bérénice, Désirée, Agréez
Morlinval	5	4	Garde-les, Morlincourt, Morlinval
Habile	5	4	Lambin, Le soleil, Habile

Œuvre [FR] : AIMARD_RIVIERE (TOP 20)

Entité	Occurrence	Max Cluster Size	Exemples
--------	------------	------------------	----------

Och	9	400	Indien Belaware, Indien, Les Indiens
Œil-de-Bœuf	7	3	Corne-bœuf !, Œil-de-Bœuf, Œil-de-bœuf
Ami	6	94	Holà, États-Unis, Hermine
Mlle	6	24	Tulle, Telles, Laquelle
Tes	6	16	Sans-Piste, Maleval, Terre Sainte
Nord	6	8	Cordieu, Bordeaux, Formé
Assis	6	8	Louisiane, Mississipi, Assis
Aigle-	6	8	Maigre, Aigle-, L'Aigle-Volant
Ohio	6	8	Ohio, L'Ohio
Est	6	7	Holà, Relevez, Sommes
Marigots	6	7	Marigots, Royal-Marine, Anse-aux-Marigots
Ward	6	7	Ward, Niagara, Gueusard
Les	6	7	Castille, Sans-Piste, Jumonville
Occident	6	6	Providence, Accidenté, Occident

Nécessité	6	6	Petit-Fort, Nécessité
Eux	6	6	Coulon, Furieuse, Joignez
Sonne	6	6	Pardonne, Pardon, Abandonnez
Avez	6	6	Bravo, Relevez, Penserez
Vire	6	5	Votre, Virginie, Vire
Rivière	6	5	Rivière, Belle Rivière, Belle-Rivière

Œuvre [FR] : AIMARD_TRAPPEURS (TOP 20)

Entité	Occurrence	Max Cluster Size	Exemples
Luz	9	298	J'ai, La Tête, Prologue
État	7	158	États-Unis, Prologue, Guaymas
Soleil	7	9	Le soleil, Pawnees, Soleil
Europe	7	6	Belhumeur, Europe, Créateur
Buffalo	7	5	Buffalo, Caballero
Och	6	71	Meegvoitch, Grande, Apacheria

Bison	6	9	Bison, Chimborazo, Habitué
Blanc	6	8	Tête-Blanche, Blancs, Durango
Voilà	6	7	Meegvoitch, Conseille, Aguilar
Rome	6	7	Rome, Prologue, Prompt
Avez	6	6	Québec, Répondez, Ouest
Cerro	6	6	Merced, Cerro de la campana, Cerro
Élan-	6	6	Noirs, L'Élan-Noir, Chinois
TUE	6	6	TUE, Habitué
Gardez	6	6	Bermudez, Accordez, Gardez
Incas	6	5	Incas, Vaincue, Convaincu
Utique	6	5	Utique, Amérique, Mexique
Écoutez	6	5	Ouaktehno, Écoutez
Vieux-Chêne	6	5	Vieux-Chêne
Hâtez	6	5	Hâtez, Arkansas

Œuvre [FR] : AUDOUX (TOP 20)

Entité	Occurrence	Max Cluster Size	Exemples
Eau	8	67	Sautons, Sologne, Douze
Saint-Jean	8	5	Saintes Huiles, Saint-Jean, La Saint-Jean
Vin	6	17	Castille, Vin, Sologne
Paris	6	8	Parfois, Gué Perdu, Marie-Aimée
Hier	6	6	Châtaigniers, Merci, Hier
Étoile	6	5	Villevieille, Castille, Bel-Œil
Tireli	6	5	Tirande, Orphelinat, Tireli
Rome	5	6	Rome, Tirande, La grosse Mélanie
Tiens	5	6	Sautons, Communs, Combien
Désiré-des-Anges	5	3	Désirée-des-Anges, Désiré-des-Anges
Quelque	5	3	Quelquefois, Augustine, Quelque
Orphelinat	5	2	Orphelinat
Combien	4	7	Communs, Bibiche, Combien
Castille	4	4	Mlle Maximilienne, Villevieille, Castille

Mélanie	4	3	Mélanie, La grosse Mélanie
Sologne	3	5	Sologne, Augustine, Sainte-Montagne
Bibiche	3	5	Bibiche
Ismérie	3	4	Ismérie, Marie-Aimée
Martine	3	2	Augustine, Martine
Douze	2	4	Douze

Œuvre [FR] : BALZAC (TOP 20)

Entité	Occurrence	Max Cluster Size	Exemples
Est	9	285	Ministère, Charivari, Gentillet
Besançon	7	6	Chapitre de la cathédrale de Besançon, A Besançon, Besançon
Afrique	7	5	Belgique, Afrique
Dent	6	84	Calard, Dent de Vilard, Charivari
Arcier	6	10	Arcier, Industrie, Tuileries
Avez	6	9	États-Romains, Salins, Romains

État	6	9	États-Romains, Rome, Autriche
Cour	6	8	Bourg, Jura, Chavoncourt
Rhin	6	7	Rhône, Dauphin, Gandolphini
Palais	6	7	Anglaise, Palais, Anglaises
Milan	6	7	Hollande, Pilate, Opéra
Loire	6	6	Chapitre, Chaire, Loire
Nouvelle	6	6	Nouvelle, Vauchelles, Granvelle
Berne	6	6	Gouvernement, Ferney, Retournez
Neuve	6	6	Gouvernement, Neuve, Rhône
Sois	6	5	Genève, Genevois, Comtois
Suisse	6	5	Suisse, Suisses, Amédée
Scey	6	5	Balthasar, Bugey, Autriche
Tinti	6	5	Bisontins, Visconti, Magdeleine
Rupt	6	5	Nobles, Hôtel National, Napolitain

Œuvre [FR] : CARRAUD (TOP 20)

Entité	Occurrence	Max Cluster Size	Exemples
Tes	9	114	Petite Jeanne, Tes, Sais-tu
Es-tu	7	8	Crois-tu, Sais-tu, Embrasse
Avez	7	6	Petite Jeanne, Voyez, Savez
Oui	6	15	Afrique, Écoutez, Voulez
Cher	6	8	Hautes-Roches, Merci, Mettez
Berry	6	7	Berry, Sylvain, Tixier
Durand	6	6	Jusserand, Durand, Grand-Bail
Tiens	6	6	Conviens, Tixier, Tiens
Pas	5	24	Jusserand, Mesdemoiselles, Afrique
Sois	5	7	Crois-tu, Mesdemoiselles, Crois
Prends	5	5	Attends, Prends, Apprenez
Vatan	5	5	Conviens, Tiens, Coupez
Laisse	5	4	Embrasse, Laisse
Paris	5	4	Grise, Paris

Bourges	5	3	Bourges
Dis-	4	14	Maman, Allons, Crois-tu
Voyez	4	7	Voyez, Voulez, Payez-les-moi
Mettez	4	5	Mettez, Nannette, Petite Jeanne
Grand-Bail	4	4	Grand-Bail, Grand Bail, Le Grand-Bail
Sais-tu	4	3	Sais-tu

Œuvre [FR] : DASH (TOP 20)

Entité	Occurrence	Max Cluster Size	Exemples
Pas	9	193	Maures, Pas, Plût
Cour	6	17	Tours, Heudicourt, Courcy
Est	6	8	Estrées, Grâces, Estrée
Clany	6	8	Cour de France, Flandre, Normandie
Oui	6	7	Soissons, Sissone, Louis-le-Grand
Mothe	6	6	Mothe-Houdancourt, Cherche, Mothe
Avez	6	6	Voyez, Cédez, Savez

Bussy	6	5	M. de Bussy, Bussy, Bussy d'Amboise
Rémond	6	5	Rémond, Beaupré, Desmonté
Rhin	5	11	Ursulines, Saint-Quentin, Interrogez
Espagne	5	8	Espagne, Deschamps, Pignerol
Anizy	5	8	Fayel, Dangeau, Anizy
Pons	5	7	Cercle, Inconséquence, Providence
France	5	6	Écu de France, Cour de France, France
Chavignon	5	5	Chapelain, Bouchavannes, Chavignon
Cossé	5	5	Cossé, Lassée, Cœur-de-Roy
Pinon	5	5	Inconséquence, Providence, Pauvre
Cédez	5	5	Cédez, Devinez, Paris
Comment	5	4	Comment, Vraiment, Parfaitement
Bohémiens	5	2	Bohémiens

Œuvre [FR] : DAUDET (TOP 20)

Entité	Occurrence	Max Cluster Size	Exemples
--------	------------	------------------	----------

Rio	8	364	Nécrophores, Cristaux, Saint-Théophile
Avez	7	5	Caveau, Turc, Savez
Pouah	6	13	Bohême, Courage, Muse sévère
Chine	6	10	Colombine, Chine, Champenoise
Cher	6	9	Perrache, Evêché, Approche
Comment	6	9	Confusément, Entrerai-je, Décidément
Sois	6	9	Champenoise, Bravo, Voyez
Bons	6	9	Bohême, Dépêchons, Bons
Montez	6	8	Montparnasse, Désir-de-plaire, Montmartre
Rome	6	8	Providence, Rome, Souwaroff
Quels	6	7	Quelquefois, Bouzanquet, Ménalque
Sonne	6	7	Ancienne maison, Grenelle, Muse sévère
Grillon	6	6	PAPILLON, Grimpe, Papillon
Naples	6	6	Tes chemises, Chenilles, Naples
Vive	6	5	Providence, Comprenez, Université

Alsace	6	5	Alsace, Alsacien, Algérien
Cévenol	6	5	Cévenole, Cévennes, Cévenol
Musette	6	5	Fouette, Eyssette, Musette
Mlle	6	5	Palerme, Vallée, Allez
Midi	6	4	Lamartine d'Elvire, Midi, Providence

Œuvre [FR] : FLAUBERT (TOP 20)

Entité	Occurrence	Max Cluster Size	Exemples
Ton	9	879	Charivari, Creton, Melun
Corse	7	6	Corse, Rudorff, Corbeil
Es-tu	7	5	Où es, As-tu cent, As-tu
Andalouse	7	4	Balandard, Andalouses, Andalouse
L'Olympe	7	3	L'Olympe, Olympe Regimbart
Turc	7	3	Turque, Turcs, Turc
Saumon	6	17	Moreau, Montereau, Longjumeau
Otant	6	16	Panthéon, Constantinople, Considérant

Assis	6	12	Suisse, Impossible, Assise
Lyon	6	12	Frisonne, Lélia, Trocadéro
Irez	6	12	Hydre, Reynolds, Foire
Rhin	6	11	Chine, Sphinx, Hiérarchie
Bray	6	11	Gymnase, Bravo, Algérie
Cour	6	11	Véfour, Pompadour, Ecoutez
Frank	6	10	Frank, Collège de France, La France
Rome	6	10	Somme, Rome, Bohême
Ponts	6	9	Poncif, Japon, Ponts
Vêpres	6	8	Sèvres, Premières, Laromiguière
Maman	6	8	Maman, Grands Lamas, Salamanque
Quels	6	8	Quelquefois, Turque, Bouquet-du-Roi

Œuvre [FR] : MAUPASSANT (TOP 20)

Entité	Occurrence	Max Cluster Size	Exemples
Qué	7	248	Quelquefois, Mignonne, Grèce

Afrique	7	6	L'Amérique, Afrique, Anti-physiques
Avez	7	5	Bravo, Fuyez, Savez
Le soleil	7	4	Le soleil
Tiens	6	10	Envoie, Impatienté, Attirée
Las	6	10	Quelquefois, Grâce, Songe
Corse	6	9	Fuyez, Corniche, La Corse
Cany	6	8	Cana, Rosalie, Religion
Mars	6	7	Sèvres, Cargèse, Mars
Normand	6	7	Hollande, Normandie, Normande
Lise	6	7	Religion, Lise, Songe
Pas de lune	6	6	Pas de lune, Le Perthuis des Vauds
Voyez	6	6	Fuyez, Sacré-Cœur, Voyez
Italie	6	6	Oriental, Italie, Rosalie
Picot	6	6	Chicorées, Vaucotte, Corniche
Suisse	6	5	Suisse, Roi-Louis, Encaissée

Chine	6	5	Chine, Romaines, Chinois
Bolbec	6	4	Bolbec, Albertacce, Gilberte
Eut	5	44	Hauts, Eut, Grèce
Folle	5	19	Hollande, Briseville, Folle

Œuvre [FR] : NOAILLES (TOP 20)

Entité	Occurrence	Max Cluster Size	Exemples
Ève	9	158	Étonnante enfance, Quelquefois, Suisse
Est	6	41	Sèvres, Bruyères, Bohême
Seine	6	9	Dauphiné, Berlin, Sabine
Montez	6	9	Pomone, Mont-Valérien, Remontée
Nancy	6	8	Étonnante enfance, Michelet, Nancy
Sois	6	8	Bohême, Assise, Bois
Azow	6	6	Hollande, Grèce, Égypte
Flore	6	6	Flore, Dauphiné, Saint-Cloud
Leurs	6	6	Asie Mineure, Elseneur, Fabien Mauri

Italie	6	5	Italie, Cordoue, Italien
Rouen	6	4	Vosges, Courbée, Rouen
Paris	6	4	Paris, Partez, Parme
Pas	6	4	Pas, Passy, Voyez
Pierre	6	3	Michelet, Pierre, Obstinée
Jacques	6	2	Jacques, Jean-Jacques
Vienne	5	7	Courbée, Lausanne, Touraine
Muette	5	6	Quelquefois, Jean-Jacques, Jacques
Tolède	5	6	Hollande, Anatolie, Tolède
Régent	5	6	Régent, Agrigente, Genève
Louvre	5	5	Sèvres, Saint-Cloud, Louvre